

# Plano de execução: deploy independente por unidade na ali-api

---

**Para:** Igor (PO) e tech lead · **De:** Diego · **Data:** 30/09/2026

**Anexos:** [Mapa de acoplamento](#) · [Estudo e prova do deploy isolado](#)

## Decisões pedidas

1. Aprovar esta trilha como card(s) próprio(s), feita **antes** do código da captura (épico 13434).
2. Aprovar as unidades-alvo e a ordem dos passos M0–M5 (M6 e M7 ficam para depois).
3. Autorizar a remoção de duas rotas legadas, se o log de acesso confirmar que ninguém as chama.
4. Acionar a infra e a administração do Azure para os itens da seção 7.

---

## 1. Por que agora

Ficou alinhado que a captura de faturas das concessionárias será feita **na ali-api**, sem que o deploy dela afete os outros módulos. Hoje isso não é possível: a ali-api tem **uma imagem, um pipeline e um deploy único**. Qualquer commit reinicia a API e o worker juntos.

O custo já aparece hoje. Nos últimos 12 meses, **54% dos commits (52 de 97) mexeram no Oracle**, e cada um deles reiniciou também a **leitura de contas pela IA**, que mudou só 5 vezes no mesmo período.

**Proposta:** manter **um repositório**, mas separar o deploy em **unidades independentes**. A captura passa a nascer como mais uma unidade, sobre uma base pronta, em vez de inaugurar o padrão sozinha.

## 2. Diagnóstico


---

O mapa completo está no anexo.

|                     |                                                                                                                                                   |
|---------------------|---------------------------------------------------------------------------------------------------------------------------------------------------|
| Acoplamento         | Na prática                                                                                                                                        |
| Deploy único        | Um pipeline disparado por qualquer commit; API, worker e infra (Redis, logs, nginx) no mesmo <code>docker compose</code>                          |
| Configuração única  | Uma classe com 12 segredos obrigatórios: <b>nenhum processo sobe sem todos</b> , inclusive a chave da AWS e a senha do Oracle, mesmo quem não usa |
| Worker único        | Leitura de conta e criação de OC no mesmo processo, presos por um único arquivo que monta os três tratadores de fila                              |
| API carrega tudo    | 105 módulos, inclusive toda a leitura por IA, por causa de <b>duas rotas legadas que o WordPress não chama mais</b>                               |
| Disco compartilhado | A API grava o arquivo e o worker de leitura o lê. Os dois precisam ficar na mesma máquina                                                         |
| Cache implícito     | A API aquece o cache do Oracle no Redis e o worker o lê, sem contrato escrito                                                                     |

**O que já está bom:** a API e o worker conversam por fila, com contratos versionados. A leitura e o Oracle compartilham só 12 módulos de base. Isso torna a separação **viável e barata**.

### 3. Onde queremos chegar



| Unidade           | Responsável por                                                     | Segredos que recebe                   |
|-------------------|---------------------------------------------------------------------|---------------------------------------|
| API               | Receber o WordPress, enfileirar, classificar itens, rotas do Oracle | Oracle, Redis, fila, WordPress        |
| Worker de leitura | Ler a conta pela IA e devolver ao WordPress                         | AWS/Texttract, Redis, fila, WordPress |
| Worker de Oracle  | Criar e excluir a OC e devolver ao WordPress                        | Oracle, Redis, fila, WordPress        |
| Infra             | Redis, coleta de logs, nginx                                        | —                                     |
| Captura (depois)  | Buscar faturas nas concessionárias                                  | Cofre, WordPress                      |

## 4. Passos

Cada passo é entregável e reversível sozinho. Tamanho: **P** até 2 dias, **M** de 3 a 5 dias, **G** mais de uma semana. É uma estimativa inicial.

| Passo                              | O que muda                                                                                              | Ganho                                                               | Tam. | Pronto quando                                                  |
|------------------------------------|---------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------|------|----------------------------------------------------------------|
| <b>M0</b> Decisão                  | ADR com as unidades-alvo; confirmar no log de acesso que as rotas legadas não têm chamador              | Direção registrada                                                  | P    | ADR aprovado; log consultado                                   |
| <b>M1</b> Higiene do deploy        | Segredos fora da imagem; deploy pela tag do build; nome de projeto no compose; infra em compose próprio | Segurança; rollback por tag; deploy da aplicação não toca a infra   | M    | Nenhuma imagem com <code>.env</code> ; API saudável em HML     |
| <b>M2</b> Rotas legadas            | Remover <code>/energy-extract</code> e <code>/extract-water</code>                                      | A API deixa de carregar a leitura por IA e a AWS (105 → 61 módulos) | P    | Suíte verde; a API sobe sem as chaves da AWS                   |
| <b>M3</b> Configuração por unidade | Cada unidade exige só as próprias variáveis                                                             | Unidades sobem independentes; cada uma só tem os próprios segredos  | M    | Cada ponto de entrada sobe só com o próprio grupo de variáveis |
| <b>M4</b> Worker dividido          | Worker de leitura e worker de Oracle, cada um com as próprias filas                                     | Mudança no Oracle para de reiniciar a leitura                       | P/M  | Em HML, as duas filas atendidas; o worker antigo desligado     |
| <b>M5</b> Pipeline por unidade     | Pipeline-modelo + um pipeline e um compose por unidade, disparados pelos arquivos de cada uma           | Deploy só do que mudou                                              | M    | Commit só no Oracle não redeploys a leitura                    |

| Passo         | O que muda                                         | Ganho                                     | Tam. | Pronto quando |
|---------------|----------------------------------------------------|-------------------------------------------|------|---------------|
| M6 (opcional) | Oracle fora do processo da API                     | Mudança no Oracle para de reiniciar a API | G    | —             |
| M7 (opcional) | Arquivo viaja na mensagem, sem disco compartilhado | API e leitura em máquinas diferentes      | M    | —             |

**Ordem:** M0 → M1 → M2 → M3 → M4 → M5. M1 e M2 podem andar juntos.

**Limite honesto:** enquanto M6 não for feito, uma mudança no Oracle ainda redeploys a API, porque a API carrega as rotas do Oracle. O ganho de M4 e M5 é proteger a **leitura de contas** e a **captura**, e não a API.

## 5. Como garantimos que nada quebra

- **Um passo por PR**, cada um com ADR, gate local e a suíte de testes automatizados da ali-api. Validado em HML antes de PRD, e o deploy de PRD continua à noite, como já é feito.
- **Sem troca brusca:**
  - o worker atual continua existindo até os workers novos provarem em HML;
  - voltar atrás é religar o anterior no compose.
- **Contratos não mudam:** as filas, as rotas usadas pelo WordPress e os callbacks continuam iguais. **Nenhuma mudança no WordPress**, exceto remover depois o código morto que chamava as rotas legadas.
- **O isolamento já foi provado** localmente em 30/09:
  - 3 deploys seguidos de uma unidade com a "API" recebendo requisição a cada 0,2 s: **446 requisições e 0 falhas**, e a API não reiniciou;
  - a prova também mostrou a única armadilha real (o nome do projeto compose), que o M1 resolve.

## 6. Impacto no épico 13434

| Sprint           | Trilha de modularização | Épico 13434                                                                                                         |
|------------------|-------------------------|---------------------------------------------------------------------------------------------------------------------|
| 30 (30/09–13/10) | M0, M1, M2              | 13438 discovery (depende de pareceres externos e anda em paralelo)                                                  |
| 31               | M3, M4, M5              | Fundação específica da captura: chave do robô no Conexão, cliente para o Conexão, cofre, navegador, banco de provas |
| 32               | —                       | 13439 base de lojas, 13440 agenda, início de 13441 motor e 13443 conector EDP                                       |
| 33 em diante     | —                       | Demais conectores e tela                                                                                            |

**Troca proposta:** o código da captura começa cerca de **uma sprint depois**. Em troca, ele nasce sobre um deploy separado e seguro, e a ali-api inteira ganha o mesmo benefício. O discovery não atrasa, porque não depende desta trilha.

## 7. Riscos e dependências

| Risco ou dependência                                                     | Mitigação ou dono                                                           |
|--------------------------------------------------------------------------|-----------------------------------------------------------------------------|
| Mexer no deploy de produção                                              | Um passo por PR, HML antes, PRD à noite, volta por tag                      |
| A VM passa a ter um processo Python a mais (worker dividido)             | Limites de CPU/memória por container; a <b>infra</b> confirma a folga       |
| Pipelines novos precisam ser registrados e autorizados no Azure          | <b>Administração do Azure DevOps</b>                                        |
| Construir imagens na própria VM de produção                              | <b>Infra</b> decide: construir na VM ou num agente separado                 |
| Mudança no núcleo compartilhado (12 módulos) redeploys todas as unidades | Esperado e raro; o gatilho por caminho cobre                                |
| Formato do cache do Oracle no Redis sem contrato                         | O cache passa a ter dono (o Oracle) e as mudanças de formato vão com versão |
| Alguém de fora ainda chamar as rotas legadas                             | M0 confirma no log antes de remover                                         |

## 8. O que peço a cada um

- **Igor:**
  - criar os cards da trilha;
  - aprovar a prioridade antes do código da captura;
  - aceitar o deslocamento de cerca de uma sprint no épico.
- **Tech lead:**
  - aprovar as unidades-alvo, a ordem M0–M5 e os ADRs;
  - autorizar a remoção das rotas legadas se o log confirmar;
  - decidir se M6 e M7 entram no radar.
- **Infra e Azure** (por intermédio do tech lead):
  - folga das VMs;
  - onde construir as imagens;
  - registro e autorização dos pipelines.